

インターネット上の気象データを利用した ニューラルネットワークによる局地降水予測*

柏尾 知明[†]・安藤 慎[‡]・池田 建司[§]・下村 隆夫[§]

Neural Network-based Local Prediction of Rainfall Using Meteorological Data on the Internet*

Tomoaki KASHIWA[†], Shin ANDO[‡], Kenji IKEDA[§] and Takao SHIMOMURA[§]

1. はじめに

近年、ヒートアイランドや温暖化を原因とした、都市型の「集中豪雨」の発生が増加している。しかしながら、夏の午後に都市内部で突然降りだす局地的大雨（局地的集中豪雨）の発生予測は非常に難しい [1]。気象庁では、数値予報モデルの一種であるメソモデルを用いて、数時間から1日先の大雨や暴風などの予報を行っているが、気象現象を表す物理方程式の時間変化をスーパーコンピュータで計算する方法である。また、気象庁のガイダンスでは降水現象を線形システムとして扱い、カルマンフィルタを用いた降水量予測を行っている [2]。一方、一般的なPC、ワークステーション上における気象予測の統計的なアプローチとしては、非線形システムを表すことができるニューラルネットワーク (Neural Network: NN) がよく用いられている [3–8]。

本報告では、関連研究で報告されていないNNによる日本各地の1年間にわたる局地降水予測と、局地性の強い東京の夏期の午後の降水予測を行う。気象データは気象庁がウェブサイト上 [9] で提供している、容易に入手できるものを用いる。最終的には、さまざまな機関、施設、個人などがインターネット上で気象データを共有しながら、一般の利用者が気象学や地学などの学問的な知識なく、局地降水予測を行えるシステムを構築し、さらには、局地的大雨を予測することを目的としている。民

間企業によるピンポイントの気象予測サービスは存在しているが、ほとんどが企業による商業ベースのもので、受動的な利用形態である。そこで本研究では、利用者みずから気象データをインターネットを介して提供しながら、利用者がお互いの気象データを用いて、任意の地域、時間の局地降水予測を手軽に行えるシステムの開発を目指している。

NNモデルとしては、多層パーセプトロン (Multi-Layer Perceptron: MLP) [5,6] と動径基底関数ネットワーク (Radial Basis Function Network: RBFN) [4,7] を用いる。一般的には、MLPよりRBFNのほうが予測性能が優れているとされているが、降雨流出予測問題におけるMLPとRBFNの比較では、その違いは決定的ではなかった [8]。そこで本報告では、日本国内の局地降水予測問題におけるMLPとRBFNの可能性を検証し、予測性能を比較する。

2. ニューラルネットワーク

本研究では、NNのモデルとしてMLPの一種である3層パーセプトロン (Three-Layer Perceptron: 3LP) を用いた (Fig. 1)。 N, M, L はそれぞれ入力層、中間層、出力層のユニット数であり (本研究では $L=1$)、 x_{ip} は出力層第 i ユニットの第 p パターンの入力信号に対するそれぞれの出力、 w_{ij}, w_{jk} は結合強度 (重み) である。それぞれのユニットの出力関数にはシグモイド関数を用いた。3LPの学習方法として、バックプロパゲーション




Fig. 1 Three-layer perceptron

[†] 新居浜工業高等専門学校 電子制御工学科 Department of Electronics and Control Engineering, National Institute of Technology, Niihama College; 7-1 Yagumo-cho, Niihama city, Ehime 792-8580, JAPAN

[‡] 愛媛大学大学院 理工学研究科 Graduate School of Institute of Science and Engineering, Ehime University; 3, Bunkyo-cho, Matsuyama city, Ehime 790-8577, JAPAN

[§] 徳島大学大学院 ソシオテクノサイエンス研究部 Graduate School of Institute of Technology and Science, The University of Tokushima; 2-1 Minamijosanjima-cho, Tokushima city, Tokushima 770-8506, JAPAN

Key Words: local rainfall prediction, precipitation, meteorological data, the Internet, neural networks.




Fig. 2 RBF Network

ン (Back Propagation: BP) 法とランダム探索法によるハイブリッドアルゴリズム [3] に改良を加えたものを用いた。

RBFN は, 3LP と似た構造をしているが, 中間層の出力関数としてガウス関数がいられる (Fig. 2). 中間層のユニット数は, 3LP, RBFN とともに $M = N$ とした。

3. 実験

本研究では, 学習データとして, 8 種類の気象データ (現地気圧, 海面気圧, 降水量, 気温, 露点温度, 蒸気圧, 湿度, 風速) をプログラムで自動収集し, Table 1 のように正規化したうえで学習データとして用いた。出力の合計降水量は, 「0.5mm 以上の場合は 1」, 「0.5mm 未満の場合は 0」とした。(一般的に降水確率は一定時間内の合計降水量が 1.0mm 以上の降水を対象としている。)

Table 1 Meteorological data and those normalization

signal	kinds of data	value range	normalized value range
input	atmospheric pressure (on-site)	940–1040 hPa	0–1
	atmospheric pressure (sea-level)	940–1040 hPa	0–1
	precipitation	above 0.5 mm/h otherwise	1 0
	temperature	-15–40 °C	0–1
	open-air temperature	-25–30 °C	0–1
	vapor pressure	0–40 hPa	0–1
	humidity	0–100%	0–1
	wind velocity	0–40 m/s	0–1
output	total precipitation	above 0.5 mm	1
		otherwise	0

3.1 松山, 札幌, 那覇の降水予測

松山, 札幌, 那覇の 2011 年の気象データを用いて NN を学習し, 2012 年の降水予測を行った。学習データは, 入力を 3,6,9,12 時のそれぞれの時点の 8 種類の気象データ (合計 32), 出力を 12~24 時の合計降水量とした。予測結果は, NN の出力が「0.5 以上の場合は発生する」, 「0.5 未満の場合は発生しない」と定義した。実験では, 予測月の前年同月 1 ヶ月間の気象データで NN を学習し, 予測月 1 ヶ月間の降水を予測した。3LP は結合荷重の初

期値を 30 回変化させながら学習を行い, RBFN はガウス関数の標準偏差を 101 パターン変化させながら予測実験を行った。

Table 3 に降水日の的中率が最も高い実験結果を示す。各月の的中率を, 降水日については「降水が的中した日数/実際の降水日の日数」, 非降水日については「非降水が的中した日数/実際の非降水日の日数」と定義した (括弧内は百分率)。降水日の的中率は, 3LP の松山の 3 月, 那覇の 3,11 月, RBFN の松山の 4,9,10,12 月, 那覇の 2,3,6,11 月を除き, 50% 以上である。また, 全体的に 3LP のほうが的中率が高い結果となった。しかしながら, RBFN のほうが降水日の的中率が高い月もあり (松山 3,7 月, 那覇 3,4 月), 必ずしも 3LP のほうが予測精度が高いとはいえない。

3.2 東京の夏期の午後の降水予測

本研究では, 次の条件を満たす降水を予測対象とした。

- (i) 6~9 月 12~24 時の 10mm/h 以上の降水である。
- (ii) 予測日の 9~12 時に 0.5mm/h 以上の降水がない。

本条件を満たす降水があった 2011 年 8,9 月と 2012 年 6,9 月各日午後の降水予測を行った。気象データの収集にあたり, 1999 年 7 月 21 日に発生した「練馬豪雨」に関する研究結果を参考とした [1]。学習データに江戸川臨海 (東京都), 我孫子 (千葉県), 海老名 (神奈川県), それぞれの 9,10,11,12 時の時点の気圧, 気温, 風速, 風向の 4 種類の気象データを加えた。また, 観測地点である東京の 9,10,11,12 時の時点の気象データに風向きを加え, 入力信号数を 84 とした。実験の条件は 3.1 と同じである。

2000~2010 年の降水日と 2010 年 8 月 or 9 月を合わせたデータで学習させ, 2011 年 8 月 or 9 月それぞれの降水を予測した。また, 2000~2011 年の降水日と 2011 年 6 月 or 9 月を合わせた気象データで学習させ, 2012 年 6 月 or 9 月それぞれの降水を予測した。

降水日の的中率が高かった学習結果の順に, 実験結果を result 1~3 (Table 2) に示す。条件 (i),(ii) を満たす降

Table 2 Prediction rate of rainfall in Tokyo 2011 and 2012: a number of prediction days/true value

rainfall day		yes	no	yes	no
month		Aug. 2011		Sept. 2011	
3LP	result 1	3/3	22/28 (78.6%)	2/2	21/27 (77.8%)
	result 2	3/3	21/28 (75.0%)	2/2	6/27 (22.2%)
	result 3	2/3	23/28 (82.1%)	1/2	23/27 (85.2%)
RBFN	result 1	3/3	18/28 (64.3%)	1/2	14/27 (51.9%)
	result 2	3/3	17/28 (60.7%)	1/2	13/27 (48.1%)
	result 3	3/3	16/28 (57.1%)	1/2	12/27 (44.4%)
month		Jun. 2012		Sept. 2012	
3LP	result 1	1/1	26/29 (89.7%)	2/2	20/27 (74.1%)
	result 2	1/1	24/29 (82.8%)	2/2	19/27 (70.4%)
	result 3	1/1	22/29 (75.9%)	2/2	16/27 (59.3%)
RBFN	result 1	1/1	15/29 (51.7%)	2/2	18/27 (66.7%)
	result 2	1/1	13/29 (44.8%)	2/2	17/27 (63.0%)
	result 3	1/1	12/29 (41.4%)	2/2	16/27 (59.3%)

Table 3 Prediction rate of precipitation in Matsuyama, Sapporo, and Naha 2012: a number of prediction days/true value

precipitation day		yes	no	yes	no	yes	no
month		Jan.		Feb.		Mar.	
Matsuyama	3LP	5/5 (100.0%)	25/25 (100.0%)	6/9 (66.7%)	14/20 (70.0%)	3/7 (42.9%)	22/23 (95.7%)
	RBFN	4/5 (80.0%)	23/25 (92.0%)	6/9 (66.7%)	18/20 (90.0%)	5/7 (71.4%)	14/23 (60.9%)
Sapporo	3LP	13/14 (92.9%)	11/17 (64.7%)	10/12 (83.3%)	10/17 (58.8%)	10/12 (83.3%)	15/19 (78.9%)
	RBFN	12/14 (85.7%)	5/17 (29.4%)	7/12 (58.3%)	13/17 (76.5%)	7/12 (58.3%)	10/19 (52.6%)
Naha	3LP	9/9 (100.0%)	12/22 (54.5%)	7/9 (77.8%)	13/20 (65.0%)	1/9 (11.1%)	22/22 (100.0%)
	RBFN	6/9 (66.7%)	12/22 (54.5%)	4/9 (44.4%)	15/20 (75.0%)	4/9 (44.4%)	18/22 (81.8%)
month		Apr.		May		Jun.	
Matsuyama	3LP	6/10 (60.0%)	16/20 (80.0%)	4/5 (80.0%)	24/26 (92.3%)	10/13 (76.9%)	15/17 (88.2%)
	RBFN	4/10 (40.0%)	14/20 (70.0%)	4/5 (80.0%)	22/26 (84.6%)	7/13 (53.8%)	16/17 (94.1%)
Sapporo	3LP	4/6 (66.7%)	21/24 (87.5%)	7/7 (100.0%)	18/24 (75.0%)	4/5 (80.0%)	25/25 (100.0%)
	RBFN	3/6 (50.0%)	19/24 (79.2%)	7/7 (100.0%)	10/24 (41.7%)	4/5 (80.0%)	20/25 (80.0%)
Naha	3LP	8/16 (50.0%)	12/14 (85.7%)	4/5 (80.0%)	19/26 (73.1%)	9/11 (81.8%)	10/19 (52.6%)
	RBFN	11/16 (68.8%)	10/14 (71.4%)	4/5 (80.0%)	19/26 (73.1%)	5/11 (45.5%)	15/19 (78.9%)
month		Jul.		Aug.		Sept	
Matsuyama	3LP	4/7 (57.1%)	22/24 (91.7%)	4/4 (100.0%)	18/27 (66.7%)	4/7 (57.1%)	21/23 (91.3%)
	RBFN	6/7 (85.7%)	4/24 (16.7%)	3/4 (75.0%)	8/27 (29.6%)	3/7 (42.9%)	21/23 (91.3%)
Sapporo	3LP	4/5 (80.0%)	13/26 (50.0%)	3/5 (60.0%)	24/26 (92.3%)	4/4 (100.0%)	19/26 (73.1%)
	RBFN	4/5 (80.0%)	13/26 (50.0%)	3/5 (60.0%)	18/26 (69.2%)	4/4 (100.0%)	8/26 (30.8%)
Naha	3LP	7/9 (77.8%)	9/22 (40.9%)	11/15 (73.3%)	10/16 (62.5%)	6/8 (75.0%)	22/22 (100.0%)
	RBFN	6/9 (66.7%)	17/22 (77.3%)	9/15 (60.0%)	14/16 (87.5%)	4/8 (50.0%)	20/22 (90.9%)
month		Oct.		Nov.		Dec.	
Matsuyama	3LP	2/3 (66.7%)	25/28 (89.3%)	5/6 (83.3%)	23/24 (95.8%)	4/8 (50.0%)	21/23 (91.3%)
	RBFN	1/3 (33.3%)	24/28 (85.7%)	5/6 (83.3%)	20/24 (83.3%)	3/8 (37.5%)	14/23 (60.9%)
Sapporo	3LP	7/12 (58.3%)	15/19 (78.9%)	17/18 (94.4%)	5/12 (41.7%)	17/23 (73.9%)	5/8 (62.5%)
	RBFN	7/12 (58.3%)	15/19 (78.9%)	10/18 (55.6%)	11/12 (91.7%)	14/23 (60.9%)	5/8 (62.5%)
Naha	3LP	5/7 (71.4%)	22/24 (91.7%)	2/6 (33.3%)	24/24 (100.0%)	5/7 (71.4%)	21/24 (87.5%)
	RBFN	4/7 (57.1%)	24/24 (100.0%)	1/6 (16.7%)	24/24 (100.0%)	4/7 (57.1%)	22/24 (91.7%)

水を、RBFN の 2011 年 9 月の結果を除いて予測することができた。しかしながら、サンプル数が非常に少ないため、有効性の検証にはさらなる実験が必要である。

4. おわりに

本研究では、気象庁のウェブサイト上の気象データを用いた NN による松山、札幌、那覇と東京の局地降水予測を行った。標高、海流、気流などの様々な条件の影響で、降水予測に適した気象データは予測地点や季節などによって異なると考えられ、さらなる的中率の向上のためには、本手法の気象データへの依存性の検証と、気象データの選択方法の開発が不可欠である。

今後の研究の展開としては、全国各地の局地降水予測を行い本手法の有効性を検証する。また、個人所有の気象データロガーのデータによる任意の地点（たとえば新居浜市八雲町 新居浜高専）の降水予測を行い、利用者が持つ個人的な気象データに基づいた局地降水予測の有効性の検証を行う。

参考文献

- [1] 三上, 大和, 安藤, 横山, 山口, 市野, 秋山, 石井: 東京都内における夏期の局地的大雨に関する研究: 東京都環境科学研究所年報, pp. 33-42 (2005)
- [2] 気象庁予報部 数値予報課: 平成 24 年度数値予報研修テキスト「数値予報の基礎知識と最新の数値予報システム」: 数値予報解説資料 (45) (2012)
- [3] 馬場, 小島, 小澤: ニューラルネットの基礎と応用, 共立出版, pp. 1-50 (1994)
- [4] 馬場, 田中, 吉富, 満倉, 半田: ソフトコンピューティングの基礎と応用 8, 共立出版, pp. 1-103 (2012)
- [5] 香村, 松田, 関根, 師玉, 山浦: ニューラルネットワークを用いた局地的な気象予測法について: 信学技法, NC94-27, pp. 25-32 (1994)
- [6] 小泉, 平沢: 降水量予測に適したニューラルネットワーク構造: 天気, 48(12), pp. 885-892 (2001)
- [7] S. Lee, S. Cho and P. M. Wong: Rainfall Prediction Using Artificial Neural Networks; *Journal of Geographic Information and Decision Analysis*, Vol. 2, No. 2, pp. 233-242 (1998)
- [8] A. R. Senthil Kumar, K. P. Sudheer, S. K. Jain and P. K. Agarwal: Rainfall-runoff modelling using artificial neural networks: comparison of network types; *Hydrological Processes*, Vol. 19, Issue 6, pp. 1277-1291 (2005)
- [9] 気象庁: 気象観測データ; <http://www.jma.go.jp/jma/menu/menureport.html>, (2014.9.21 アクセス)