

基準需要を利用したニューラルネットによる 翌日最大電力需要予測

正員 須貝 康雄 (千葉大)

非会員 堀 部 浩* (千葉大)

正員 川 瀬 太郎 (千葉大)

Forecast of Daily Maximum Electric Load by Neural Networks using the Standard Electric Load

Yasuo Sugai, Member, Hiroshi Horibe, Non-member, Taro Kawase, Member (Chiba University)

This paper proposes a new method for the forecast of daily maximum electric load by using feedforward neural networks and recurrent neural networks. While the maximum electric load mostly depends on the weather conditions of the day, it is important for the forecast to consider the influence of the load or the weather conditions for the past few days. The proposed method consists of two steps in the learning stage. In the first step, the feedforward networks learn the standard electric load corresponding to the weather conditions of the day in which the load is to be predicted. In the second step, the recurrent networks learn the difference between the standard electric load and the measured one. The load forecast is executed as follows: the feedforward networks output the standard load after the weather conditions of the day are inputted. The final result of the load forecast is obtained as for the output of the recurrent networks which correct the standard load considering the time dependency of electric load. Computational experiments show the high abilities of the proposed method so that the annual average error of the forecast for weekdays is 1.7%.

キーワード：リカレントニューラルネット，最大電力需要予測，基準需要，時系列データ

1. はじめに

電力需要の予測は電力会社にとって、安定した電力供給の維持および経済的に効率的な系統運用に不可欠である。特に毎日の最大電力需要を的確に予測することは重要であり、重回帰分析をはじめとする様々な手法が用いられ、予測精度向上への努力がなされている⁽¹⁾。電力需要は、過去数日間の気象条件（最高気温・最低気温・湿度・天気など）や電力需要・曜日・景気動向・季節などが複雑にからみ合う、膨大な時系列データであるといわれていて、その予測には様々な時点での過去の時間遅れ要素をとらえたうえで、入出力データ間の相互関係を表現できるモデルが必要となる。

このようなことから、最近ニューラルネットワーク（以下、NNと略記）を用いた時系列データ予測の研究が多く行われている。これはNNのもつ特徴抽出能力、未学習データに対する汎化能力に着目した研究であり、重回帰分析では解析しにくい大規模な時系列データに対して有効

であると考えられている⁽²⁾。NNにはフィードフォワード型（以下、FNNと略記）とリカレント型（以下、RNNと略記）があるが、一般にRNNは自己回帰的な結合や同じ層間の相互結合などがあり、FNNと比較して、より直接的に時系列データを扱える⁽³⁾。従って、時系列データである電力需要予測に対してはRNNを用いるのが有効であると考えられる⁽⁴⁾。

一般にNNにおいては、入出力に用いるデータを(0,1)の範囲に規格化する場合が多い。しかし、NNを用いて電力需要を予測する際に、一つの電力会社で扱う電力は 10^4 MWにも及ぶため、NNのわずかな誤差が電力の絶対量としては非常に大きな量になる。一方、どのようなNNを用いても誤差をなくすることは不可能であるから、同じ大きさの誤差でも、電力需要に換算した場合に、その誤差が電力需要の絶対値に対してなるべく影響しないようなシステム構成が重要だと考えられる。著者らはこの点を考慮し、次のような予測手法をとった。

電力需要は時系列データではあるが、予測当日の気象条件による影響が最も大きいことが知られていて、予測当日が同じ気象条件のときは後述する特異日などを除けば、電

* 現在、名古屋大学大学院工学研究科前期博士過程在学中

力需要も同程度と考えられる。そこで、予測当日の気象（正確には気象庁などの予測気象）条件だけから、おおよその需要を算出できれば、これはある気象条件に対応する基準需要（以下、ベースと呼ぶ）とみなすことができる。このベースは、予測当日の気象条件だけを考慮すればよいので、RNN である必要はなく、FNN を用いてベースを学習させればよいと考えられる。

次の段階として、RNN を用いて時系列的な要素を考慮した精密な需要予測を行うことを考える。時系列の学習には気象条件、および需要の絶対量ではなく、前日との気象条件の差を RNN の入力データとし、実測値と基準値との差を教師データとする。RNN で再び気象条件を入力することと、相対量を用いる理由については後述する。

このようにすれば、時系列データを直接扱えるという利点を生かした RNN への入力データが作成でき、また相対量を用いることで、絶対量に比較して予測する幅が小さくなるので、つまり (0, 1) の範囲に規格化される電力需要の幅が小さくなるので、同じ誤差でも電力需要の絶対量への影響を小さくでき、高精度の予測が可能になることが期待できる⁽⁸⁾⁽⁹⁾。

本論文では、翌日最大電力需要予測に関して、以上のような FNN と RNN の特徴を生かした 2 段階の予測手法を提案する。平日の需要予測に対する計算機実験では、年間平均予測誤差は 1.7% となり、提案手法の有効性を確認した。以下、第 2 章で予測に用いる FNN および RNN の構造と、用いるデータの処理方法について述べる。第 3 章では提案する予測手法について述べ、第 4 章では提案手法の有効性を検証するための計算機実験とその結果を示す。第 5 章は結論と今後の課題である。

2. ネットワーク構造と入力データ処理

〈2・1〉 予測のための NN の構造 図 1 に翌日最大電力需要予測用の FNN と RNN を示す。これらは層構造モデルとして一般的な入力層、中間層、出力層の 3 層構造からなるネットワークである。各層には処理ユニットがいくつか並び、各ユニットは他のユニットから送られてくる信号を処理した後、別のユニットへ出力を伝達する。これらの集合体としてネットワーク全体が機能し、最終的な出力が得られる。これら二つのネットワークの大きな違いとして、RNN の場合、出力層ユニットから中間層ユニットへのフィードバック結合、中間層ユニット間の結合や自己ループ結合があり、これらの結合を通じて、過去に輸入された信号が伝達される。そして、その信号を受け取ったユニットは現時刻の信号と並行して過去の入力情報も処理できる。このため、時系列データの学習には、RNN のほうが適していると考えられる。

より明確には、予測日 t における電力需要を $L(t)$ とし、気温、湿度などの気象条件をまとめて $W(t)$ とすると、電力需要 $L(t)$ は (1) 式により表現されると仮定する。




図 1 ニューラルネットワークの構造

Fig. 1. Neural network models.

$$L(t) = f(W(t), W(t-1), \dots, L(t-1), L(t-2), \dots, t, t-1, \dots) \quad (1)$$

実際には (1) 式に社会的経済的要因が加わると考えられる。電力需要は予測当日の気象条件に最も大きく影響を受けることを考慮し、次の仮定として、(1) 式の f が (2) 式のように分けられるとする。

$$f = f_1 + f_2 \quad (2)$$

$$f_1 = f_1(W(t), t) \quad (3)$$

$$f_2 = f_2(W(t), W(t-1), \dots, L(t-1), L(t-2), \dots, t, t-1, \dots) \quad (4)$$

(2) 式は、予測日の気象条件だけに依存する部分 f_1 と、それ以外の部分 f_2 から成り立っている。基準需要は (3) 式に対応し、 f_1 の値は FNN を用いて算出する。また、電力需要および気象の時系列性に依存する部分は、(4) 式に対応する。 f_2 の値は RNN を用いて算出し、最後に (2) 式により、予測日 t の需要 $L(t)$ を算出する。ここで注意すべき点は、(4) 式にも予測日の気象条件 $W(t)$ が含まれていることである。(3) 式はあくまでも予測日 t の気象条件だけの関数として分離できる項であり、 $W(t)$ と、 $W(t-1)$ などの両者に依存する項は依然として f_2 中に含まれる。

NN の学習方法は、FNN では Back-Propagation 法（以下、BP 法と略記）⁽⁶⁾ を用い、RNN における学習では、学習則の定式化の際、多段の信号伝達回路は無視して、出力層ユニットから中間層ユニットへの直接の誤差伝搬だけを用いた、近似的最急降下法である直接型 BP 法を採用する⁽⁶⁾⁽⁷⁾。また、FNN、RNN における各ユニットには、他の複数のユニットからの信号の重み付き和を入力として受け取り、sigmoid 関数により [0, 1] の値に非線形変換した値を出力する、一般的なニューロンモデルを用いる。

〈2・2〉 データの規格化 学習・予測の際、ネットワークに与えるデータの規格化を行う。次のように、用いるネットワークに応じて二つの方法を用いる。

(1) FNN で使用するデータを規格化する場合

$$\text{規格化値} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \times a + b \quad (5)$$

(2) RNN で使用するデータを規格化する場合

$$\text{規格化値} = \frac{X + \frac{|X|_{\max}}{0.5}}{2 \times \frac{|X|_{\max}}{0.5}} \times a + b \quad \dots\dots\dots (6)$$

X は規格化するデータであり、 X_{\max} 、 X_{\min} はそれぞれ需要予測を行う年の前年までのデータの最大値、最小値である。 a ($0 < a < 1$)、 b ($2b = 1 - a$) は予測時に規格化値が $[0, 1]$ の範囲から逸脱しないように余裕をもたせる意味で、規格化の幅を狭くするために設定する。また、(6)式では実測値とベース値との差が ± 0 のときに規格化値が 0.5 となるようにしている。

気象データの一つとして用いる天気データの規格化は、電灯使用などの照度に関係するデータであることから、晴れを 0.1 、曇りを 0.4 、雨を 0.9 、雪 0.8 とした。値そのものは予備実験により決定した⁽⁴⁾。

〈2・3〉 入力データの前処理 図1の二つの NN への入力データに関しては、前述のように電力需要の絶対量が大きいことを考慮し、ネットワークの誤差が需要量に直接影響することをなるべく避けるための解決方法として、図2のように二段階に分けて予測する方法を提案する。まず1段目の予測として、予測当日の気象条件と電力需要の関係をとらえた基準需要を FNN で設定し (〈3・1〉節、2段目で、実測値と基準値との差を用いて、時系列性を考慮した予測を RNN により行う (〈3・2〉節)。計算機実験に用いるデータは、1988 年 1 月 1 日から 1993 年 12 月 31 日までの期間のうち、土曜日や祝日付近・正月・お盆・ゴールデンウィークなどの特異日を除いた平日データ 6 年分である。具体的には 1988 年：231 日間、1989 年：232 日間、1990 年：236 日間、1991 年：233 日間、1992 年：230 日間、1993 年：225 日間の計 1,387 日間である。予測はある特定の 1 年間を通じて行う。ただし 1 年を一定期間に分割して、その期間ごとにネットワークを構築し、それぞれのネットワークにより翌日最大電力予測を行う。予測期間を分割する理由、および平日の予測に限定する理由を以下に述べる。

気象条件と電力需要の関係は季節によって大きく変化する。

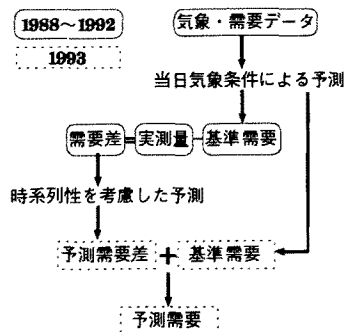


図 2 予測方法
Fig. 2. Proposal method.

る。また、1日の最大電力需要は、夏期においては最も気温の上昇する日中後に発生するのに対し、秋期は夕刻に、冬期は午前または夕刻、春期は午前または午後発生することが多い。更に、予測期間が長いと気象条件とは別の社会的状況による電力需要の日ごとの伸びにより、同じ気象条件でもばらつきが大きくなる。このように、1年を通して一つのネットワークで予測を行うことは、予測精度の悪化に結びつくと考えられる。従って、高い予測精度を得るには、予測期間を短く限定する必要がある。そこで、1か月を一つの予測期間とし、予測期間ごとにネットワークを割り当てる。

平日だけの予測を行う理由は、土曜日や特異日においては電力需要を大きく左右させるのは、気象条件以外の要因であるため、電力需要が極端に減少し、電力消費の傾向が異なるためである。今回 NN への入力は、気象データに限定しているため、それ以外の要因から生じた電力需要の傾向を学習させようとする、全体としての予測精度が悪化することが予想される。もちろん、気象条件以外の要因として考えられる社会的要因、例えば、土、日曜日や特異日は休業とする企業が多いなどの状況や、景気の動向などの経済的要因を考慮した NN を構成することも可能であるが、これらの要因についてはより長期的な経済予測や長期電力需要予測の予測結果に基づいて、NN の出力 (予測需要) を補正するというかたちで取り入れたほうが妥当であると考えられる。

3. 予測方法

〈3・1〉 基準需要の作成 図3は、年ごとの特異日を除いた最高気温と最大電力需要の関係を示している。縦軸は最大電力需要に多少幅をもたせたいうで、 $[0, 1]$ に規格化している。以下においても電力需要はすべて規格化して表現する。

電力需要は年々増加しているが、年ごとに伸び方が異なり、その伸び率は、その年の長期的気候や経済状況によって大きく左右される。基準需要の作成に関しては、複数年のデータを用いてばらつきの少ないネットワークを作成す




図 3 最高気温と最大電力需要の関係
Fig. 3. The relation between the highest temperature of the day and the electric load.

る必要があるが、そのためには年ごとの電力需要の伸びを考慮に入れる必要がある。そこで、過去のデータをネットワークに学習させる際、その伸びを考慮して、予測期間の電力需要に相当するように補正した電力需要で学習させることを考える。

また、年ごとの予測期間の特異日祝休日を除いた最高気温と最大電力需要の関係は、電力需要の伸び以外は同様の関係にあり、つまり気温 20°C 近辺を境にして、温度差が大きくなるほど電力需要が増加している (図3)。ある期間ごとに最小二乗法を用いて一定期間の最高気温と最大電力需要の関係を年ごとに二次近似したのが図4(a)である。この図は10月を例としている。この期間の平均最高気温時の電力需要に基づいて伸び率を求め、その伸び率に従って図4(b)のような補正した。同図からわかるように、この方法により、年ごとの平均最高気温の変化にほぼ対応できることがわかる。

次に、予測年の前年からの需要の伸び率を予測する必要があるが、年に依存し、この伸び率を求めるには、経済状態などの指標を考慮する必要がある。これらを数値化して、伸び率を予測するのは困難であるため、次の二種類の方法でデータの補正を行った。

〔方法1〕 予測期間前の特異日祝休日を除いた50日分の前年の同期間からの伸び率を図4と同様にして求め、これを予測期間の前年からの需要の伸び率として、過去の需要を伸び率倍して補正する。

〔方法2〕 予測日前50日分の需要データを用いた二次近似を行って、伸び率を求めたうえで補正する。そし

て、この操作を日ごとに行う。

ネットワークの学習に用いるデータは、予測年の前年までのデータとする。予測および学習に用いる入力データとしては、電力会社で主に用いられているデータに習い、最高気温 ($^{\circ}\text{C}$)、最低気温 ($^{\circ}\text{C}$)、平均湿度 (%), 天気である。各指標データは〈2・2〉節で述べたように、 $[0, 1]$ の間で規格化した後、ネットワークに入力する。

ベースは以下の手順で設定する。手順を図5に示す。ベースは、当日気象条件だけを考慮すればよいので、RNNである必要はなく、簡単な構造で計算量が少ないFNNを用いる。

(1) 予測前年までの予測期間を学習期間とし (予測期間が1993年8月の場合、学習期間は1988~1992年8月)、気象条件 (最高気温、最低気温、湿度、天気データ) と補正した電力需要の相互の関連性を、図1(a)のFNNに学習させる。その際、気象条件を入力データ、最大電力需要を教師データとする。ここでの学習では、時系列性を考慮していないため、学習データをランダムにFNNに提示する。

(2) 学習期間の気象条件を学習させたFNNに、予測期間の気象条件を入力し、その出力を予測期間に対する基準需要とする。

ネットワークを学習させる際、学習前のネットワークの結合重みの初期値や学習回数により収束状態が異なるため、ベース値は重みの初期値に依存する。しかしながら、ベースがある程度安定していないと、2段目のRNNで予測する際、ばらつきが大きくなる。そこで、重みの初期値に依存しにくいベース値を作成するため、各ユニットの重みの初期状態を変えて、10回学習を行い、得られた10種類のネットワークの平均出力値をベース値として採用した。

〈3・2〉 時系列性の考慮 二段目のネットワークであるRNNでは、時系列性を学習させる目的で、図6のようなネットワークを学習と予測に用いる。電力需要の時系列性を考える場合、電力需要そのものの時系列性と、気象




図4 電力需要の補正方法 (10月の例)
Fig. 4. The correction of the electric load.

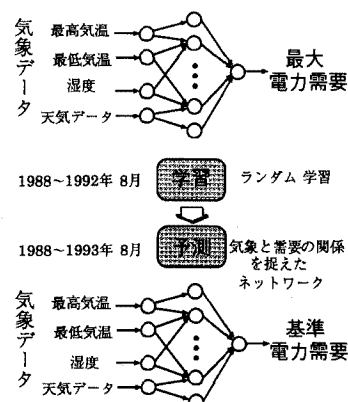


図5 基準需要の作成方法の概念図 (8月の例)
Fig. 5. The method of obtaining the standard electric load.

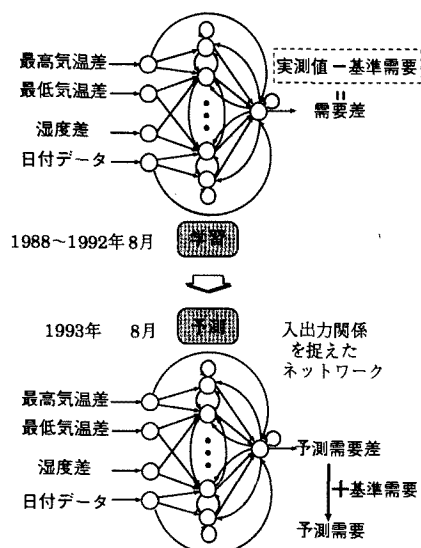


図 6 時系列性を考慮した予測 (8月の例)
Fig. 6. The method of considering dependence of the electric load on the past few days.

条件の時系列性が需要に反映した結果としての時系列性が考えられる。実際はどちらであるか不明である。あるいは、両者がからんでいることや、更に別の要因により、総合的に電力需要の時系列性として現れていることも考えられる。

重回帰分析では、原因として考えられる要素を説明変数として、明確にモデルに取り入れる必要がある。その点、RNNを用いる利点としては、不確かな部分があっても、出力層ユニットに自己ループ結合を設けることで、電力需要そのものの時系列性を考慮でき、入力に気象データを用いることで、気象条件の時系列性も扱える。更に、RNNの学習による自己組織化能力により、適切な時系列性の学習が期待できる。

ところで、予測日の気象条件に対応する電力需要については、既にFNNにより学習済みである。RNNには時系列性に関してだけ学習させる工夫が必要である。気象データの絶対量をRNNに入力する場合、RNNは(1)式を学習することになる。つまり、当日の気象条件に対応する需要についての学習も含まれる。目的は(4)式の学習であり、かつ f_2 には予測日の気象条件 $W(t)$ が含まれる。

以上のことから、RNNに関しては図6のように、気象データの絶対量は用いず、前日と予測日との最高気温差、最低気温差、湿度差という相対量を入力データとする。対応して出力についても、(2)式から明らかのように、実測値と基準需要との需要差が学習データになる。予測時にも同様に需要差が出力される。

また、学習の際、RNNは年の変わり目を認識できず、日々の伸びに対応できなくなることに対処するために、日付データを入力データとして加える。日付データとは、予測期間開始日から終了日までの間の日付を年単位で{0, 1}

に規格化した値である。

$$\text{日付データ} = \frac{X}{N} \times a + b \dots\dots\dots (7)$$

ただし、 X : 予測期間開始日からの日数、 N : 予測期間の日数、 $a, b: 0 < a < 1, 2b = 1 - a$

ここで、 a, b は(5)、(6)式における a, b と同一で、規格化のためのパラメータである。RNNに時系列性を学習させるために、予測期間のデータを順番にネットワークに入力し、それを繰り返すことで学習を行う。また本論文では、基準需要と実測値の差をRNNを用いて、時系列性を考慮して平日の予測をしている。このため、特異日のデータを除いた直後は、電力需要の時系列性が失われるので、学習や予測の際、その時点でRNNの各ユニットに残っている活性値をリセットすることで対処する。

学習後の予測についてまとめると、予測日の気象条件と前日との気象条件の差を、それぞれ学習済みのFNNとRNNに入力し、FNNから出力される基準需要にRNNから出力される補正分を加え合わせ、更に、需要に換算したうえで予測需要とする。

4. 計算機実験

4・1) 予測結果の評価法および実験方法 本実験では、ネットワークの予測の精度を評価するための尺度として、平均誤差率を用いる。まず、誤差率とは、日ごとの予測値と実測値との間の誤差の実測値に占める割合である。また同様にして、ベース値を評価する尺度としてベース誤差率を設定する。誤差率およびベース誤差率をそれぞれ(8)式および(9)式に示す。

$$\text{誤差率}(\%) = \frac{|\text{実測値} - \text{予測値}|}{\text{実測値}} \times 100 \dots\dots\dots (8)$$

$$\text{ベース誤差率}(\%) = \frac{|\text{実測値} - \text{ベース値}|}{\text{実測値}} \times 100 \dots\dots\dots (9)$$

また、平均誤差率および平均ベース誤差率とは、予測期間の誤差の絶対値平均のことである。

提案方法に関する計算機実験は以下の設定条件で行った。(5)~(7)式における定数 a, b の値は、予備実験により $a=0.8, b=0.1$ とした。計算機実験では、3・1節で述べた電力需要の伸びの補正方法二つについて実験した。

〔方法1〕 電力需要の伸びを予測期間前の50日間分で補正する。

〔方法2〕 電力需要の伸びを日ごとに予測日前50日間分で補正する。

学習の終了条件には、学習誤差と学習回数の両方を用いる。すなわち、学習誤差が減少しなくなるか、学習回数あらかじめ定めたある回数 N に達するかのどちらかの時点で学習を終了する。学習回数1回は、入力データ(予測期間の学習データ)の各々をネットワークに1回ずつ提示

することを意味する。本実験では予備実験に基づき、 $N=8,000$ を用いている。

ネットワークの構造は、FNN、RNNともに入力層ユニット数4、出力層ユニット数1(図5、図6参照)であり、中間層ユニット数に関しては、FNNは8個、RNNは10個とした。また、ユニット間の結合に関しては、FNNでは層間全結合とし、RNNでは出力層ユニットから入力層ユニットへの結合、中間層ユニットから入力層ユニットへの結合、入力層ユニットの自己ループ結合、これら3種類以外のすべての結合を設定している。FNNとRNNの中間層ユニット数と、RNNのユニット間の結合の仕方は、予備実験結果とRNNの最適構造決定手法の実験結果⁽⁴⁾を参考に決定した。

〈4・2〉 実験結果 予測は気象庁からの予測当日の気象予報データ入手の時点で行うことを仮定している。実験では提案手法自体の有効性を検証するために、予測当日の気象データの実測値(温度については小数点以下第1位までの数値、湿度については整数値(%))を用いている。従って、実際の予測誤差は実験結果の予測誤差に、気象庁の予報誤差が加わった値となる。

表1、表2に実験結果を示す。すべての予測値は、NNの結合重みの初期値を変えて、10回試行した平均値である。表1は1993年の予測を行った結果である。そして、平均誤差率と同様に重要だと考えられる最大誤差率につい

ても調べた結果、最も誤差率が大きかったのは7月14日(水)で、ベースでの誤差が8.42%、予測誤差が7.85%であった。なお、この誤差は実測値が予測値を超えたことにより生じている。電力供給不足を避けるための予備の電力を全体の10%程度とすると、この最大誤差は予備率の範囲内にあると考えられる。

また、表1の結果が予測年の傾向だけに依存している可能性もあるため、1993年だけでなく、1992、1991年の予測も行なった結果が表2である。予測のためには、基本的に予測当日以前のすべてのデータが使用可能であると仮定していることと、実験では1988年以降のデータを用いているため、1991、1992、1993年の順番で利用できる過去のデータが多くなる。

1991、1992年の予測は、1993年と同じように予測日前までのデータにより予測した結果である。“ベース”欄は気象条件だけからFNNにより得られた中間段階の予測結果であり、“予測”欄は時系列性を考慮したRNNにより得られた結果である。従って、二つの欄の誤差率の差が、時系列性が関与している部分であると考えられる。

一つのNNの学習に必要な計算時間はSUN Sparc Station 5相当でFNNは平均約3分、RNNでは平均約8分であった。また、予測自体は瞬時にできる。

これらの結果を詳しく見てみると、予測誤差率の大きい予測期間においては、年の電力需要の伸びの補正が不十分で、全体的にベース値が実測値とずれたためであることがわかった。[方法2]のほうが[方法1]よりも結果が良好なのは、[方法1]が予測期間前のデータから補正しているのに対し、[方法2]は予測日前至近日のデータを用いて補正しているので、ベースと実測値が極端にずれる期間が少なく、補正がより適切に行われたためだと考えられる。

実験では年別の予測を行ったが、全体的には学習データが増えるほど予測結果が良い。1991年の予測には3年分のデータを用いるのに対して、1993年の予測には5年分のデータを用いている。電力需要には当日の気象条件と前日以前の時系列的要因の両者が影響すると考えられるが、FNNを用いてベースを作成する際には、時系列的要因が影響している分も区別しないで学習している。データ量が少ない場合には、そのデータに含まれる時系列性がベースに強く影響するが、データが多くなると、時系列性が打ち消され、純粹に当日の気象条件だけに対応するベースが生成されることが考えられる。従って、学習データが増えれば、学習時間は増すが、より精度の高いベースが得られることが期待できる。

また、予測条件が異なるので正確な比較はできないが、直接的にNNを用いる方法による2.28%という予測結果⁽⁴⁾と比較して、提案手法による結果のほうが良好と考えられる。予測の結果の一例として、1993年9月(〔方法2〕)の予測結果を図7に示す。横軸は平日の日付に連番番号を付けた日付番号を表す。

以上の実験で用いた気象データ、特に電力需要への影響

表1 実験結果(1993年)


Table 1. The experimental results of 1993.

期間	平均誤差率(%)			
	方法1		方法2	
	予測	ベース	予測	ベース
1/01-1/31	2.529	2.532	1.053	1.039
2/01-2/28	2.149	2.297	1.585	1.816
3/01-3/31	1.642	1.937	1.744	1.831
4/01-4/30	2.075	2.242	1.462	1.569
5/01-5/31	1.726	2.207	2.018	2.203
6/01-6/30	1.474	1.914	2.074	2.499
7/01-7/31	2.238	2.667	2.126	2.504
8/01-8/31	1.125	1.977	1.400	2.275
9/01-9/30	1.063	1.973	1.406	1.637
10/01-10/30	1.258	1.428	2.375	2.279
11/01-11/31	2.529	2.933	1.237	1.657
12/01-12/31	2.949	2.855	1.635	1.471
93年平均	1.888	2.237	1.699	1.916

表2 実験結果(1991、1992年)

Table 2. The experimental results of 1991 and 1992.

予測年	年間平均誤差率(%)		
		年間平均誤差率(%)	
		予測	ベース
1991年	方法1	2.144	2.317
	方法2	2.080	2.261
1992年	方法1	1.797	1.941
	方法2	1.748	1.892



実線：予測値，破線：実測値，点線：ベース値

図 7 1993 年 9 月の最大需要予測結果 ([方法 2])
Fig. 7. The experimental result of September in 1993.

の大きい気温データは，小数点以下第 1 位までの実測値である。前述のように，実際の予測誤差は，実験結果に気象予報誤差が加わった値になる。気象予報の予測精度に関する詳細については，本論文では考察の対象外としているが，予報精度が向上しても，整数値として予報される現状と，小数点以下第 1 位までの実測値を用いた実験結果との相違は重要であると考えられる。特に提案手法では，気象データを 2 段階で用いていることと，2 段階目の RNN では前日との気象の差を入力しているため，他の手法と比較して予報誤差の影響を受けやすいことが考えられる。

そこで，学習済みのネットワークを用いて，[方法 2]による以下の追加実験を行った。1 段階目の FNN では，受ける予報誤差の影響は他手法と同程度であると仮定し，気象データの実測値を用いた。2 段階目の RNN では，気象予報が整数値であることを考慮し，実測値の小数点以下第 1 位を四捨五入することにより，整数値化した気温データを用いた。その結果，1993 年の年間平均予測誤差は 0.090%悪化した。表 1 では，1 段階目のネットワークだけを用いた基準需要の平均誤差が 1.916%，RNN による補正後の平均誤差が 1.699%であるので，RNN による予測精度の向上は 0.217%分である。よって，気象予報が整数値であることを考慮しても，2 段階方式による提案手法が有利であることがわかる。しかしながら，この結果は理想的な気象予報を仮定した場合である。そのため，気象予報の精度が悪いと，RNN による需要の補正が，逆に電力需要予測精度を悪化させる可能性が十分あることに注意すべきと考えられる。

5. おわりに

本論文では，翌日最大電力需要予測を行う際，当日気象条件の影響と時系列性の影響を考慮し，それぞれを FNN と RNN による 2 段階方式で予測する手法を提案した。そして，計算機実験により本手法の有効性を示した。また，気象予報誤差が提案手法に与える影響についても，追加実験に基づき考察した。

翌日最大電力需要予測には予測精度向上のため回帰分析をはじめとする様々な手法が用いられているが，予測誤差 2%台が大きな壁だといわれている。提案手法では，3 年間の特異日を除いた予測を行った結果，最も多くの学習データが利用可能であった 1993 年の需要予測では，平均誤差率が約 1.7%と安定した結果が得られ，回帰分析と比較しても良好な結果であると考えられる。

本論文では，〈2・3〉節で述べた理由により，需要予測を平日に限定した。特異日に関しては，電力会社では特異日用のモデルを構築する，あるいは，経験により得られた平日と特異日間の換算係数を用いて，予測需要を補正するという手段で対処している。提案手法についても，特異日に関する基準需要を作成することは平日と全く同様に行える。特異日と平日の基準需要を比較することにより，平日と特異日との間の換算係数を求めることは可能であると考えられる。適切な換算係数が得られれば，平日と特異日の区別なく，RNN を用いた学習が可能である。しかしながら，前述のように，社会的経済的要因が強く影響すると考えられる特異日に関しては，適切な換算係数が得られるかどうかという点で課題が残る。

上記の課題に加えて，他手法の予測結果との詳細な比較検討，および本手法では予測前年からの電力需要の伸びを予測して補正しているが，補正の仕方がかなり予測結果に直接影響してしまう場合があり，ベースを用いない方法よりもかえって予測精度が低下してしまう期間がある。経済指標を用いるなどの改善が今後の課題であると考えられる。

(平成 8 年 9 月 18 日受付，同 9 年 2 月 5 日再受付)

文 献

- (1) 灰田武史・大橋敏明・武藤昭一：「最大需要予測支援システムの予測精度向上に関する検討(3)」，平 6 電気学会電力・エネルギー部門大会，No. 263，123～124
- (2) 木本 隆・浅川和雄，他：「ニューラル・ネットワークによる株式市場予測」，信学技報，NC90-10 (平 2)
- (3) 大崎洋一郎・永野 俊：「多層神経回路網による経済指標の予測」，同上，NC91-131 (平 3)
- (4) 加藤裕之・須貝康雄・川瀬太郎：「GA を利用したリカレントニューラルネットによる翌日最大電力需要予測」，電学論 B，115，875～882 (平 7-8)
- (5) D. E. Rumelhart, G. E. Hinton & R. J. Williams: "Learning representations by back-propagating errors", *NATURE*, 323, 533～536 (1986)
- (6) 銅谷賢治・吉澤修治：「時間パターンの神経回路モデル」，信学論 D-II，J73-D-II，1150～1157 (平 2-8)
- (7) 銅谷賢治：「リカレントネットワークの学習アルゴリズム」，計測と制御，30，No. 4，296～301 (平 3)
- (8) 和田 茂・須貝康雄：「基準需要量を利用したリカレントネットによる翌日最大電力需要量の予測」，平 6 電気学会電力・エネルギー部門大会，No. 258，113～114
- (9) 福井貴明・須貝康雄：「リカレントネットによる翌日最大電力需要予測—最高気温に基づく基準需要の利用—」，平 7 電気学会大会，分冊 6，No. 1399，292～293
- (10) 今井紀子・堀部 浩・須貝康雄・川瀬太郎：「ニューラルネットを用いた基準需要に基づく翌日最大電力需要予測」，平 8 電気学会電力・エネルギー部門大会 (論文 II)，No. 249，97～98

須 貝 康 雄




(正員) 1985年東京工業大学大学院理工学研究科情報工学専攻博士課程修了。1986年千葉大学工学部助手, 1991年同助教授となり, 現在に至る。大規模システムおよびニューロンコンピュータなどの分散システムの研究に従事。工学博士。電子情報通信学会, 情報処理学会, 計測自動制御学会会員。

川 瀬 太 郎



(正員) 1966年東京大学大学院工学系研究科博士課程修了。1977年千葉大学工学部教授となり, 現在に至る。電気設備, 配電, 屋内配線, 接地の研究に従事。工学博士。照明学会, 電気設備学会, 建築学会会員。

堀 部 浩



(非会員) 1996年千葉大学工学部電気工学科卒業。同年名古屋大学大学院工学研究科博士課程前期課程入学, 現在に至る。ニューラルネットワークに興味をもつ。

